Knowledge Management & Graphs Concepts

Fabien FURFARO

24 juillet 2025

Sommaire

- Présentation du contexte et du besoin
 - Historique
 - Défis actuels et objectifs
 - Composants d'un KMS moderne
 - Cas d'usage : Curiosity
 - Bénéfices et limites
 - Exemple concret : aéronautique
 - Approche Capgemini « Trust before technology »
- Présentation des compétences nécessaires
 - Théorie et concepts fondamentaux
 - Graphes et connaissance
 - Sémantique, ontologies
 - Vectorisation et recherche sémantique
 - IA et NLP
 - Mathématiques et algorithmes de base
 - Exemple pratique de requête sur un LPG



Historique

La gestion des connaissances (Knowledge Management) a évolué en plusieurs phases :

- Avant 1980 : pratiques informelles, catalogage manuel, échanges oraux.
- 1980-1995 : premiers outils informatiques et bases de connaissances structurées.
- 1995-2010 : plateformes collaboratives, moteurs de recherche spécialisés.
- 2010 et après : NLP/NLU, graph databases, transformers, accent sur gouvernance et modélisation.

Défis actuels et objectifs

- Fragmentation de l'information et silos de données.
- Hétérogénéité des systèmes.
- Perte du savoir par turnover ou absence de capitalisation.

Objectif : créer des plateformes « Google-like », capables de retrouver et structurer la connaissance avec un KMS (Knowledge Management System) s'appuyant sur curation humaine, ontologie métier, indexation croisée et technologies avancées (ex : knowledge graph, IA).

Composants d'un KMS moderne

- Modèles formels, ontologies.
- Moteurs de règle, systèmes experts.
- Knowledge graph, sémantique.
- IA (NLP/NLU, entity recognition, retrieval).
- Interfaces LLM/RAG, intégration outils métier.

Cas d'usage : Curiosity

- KMS basé sur un Linked Property Graph (LPG) développé en C#.
- Détection automatique et pondération des entités (NLP).
- Recherche par similarité (subgraph embedding, vectorisation texte).
- Rapidité sur grands volumes (plusieurs centaines de milliers de docs).

Bénéfices et limites

- Gain de temps, pertinence, efficacité de support client
- Sécurité du patrimoine informationnel
- Défis persistants de désilotage, capitalisation experte, automatisation des process

Exemple concret : aéronautique

Déploiement progressif chez un avionneur : de 15 000 utilisateurs internes à plus de 100 000 clients externes, grâce à la puissance du knowledge graph pour résoudre des problématiques techniques complexes.

Approche Capgemini « Trust before technology »

 Diagnostic métier et technique approfondi, co-construction humaine + technologique, prototypage rapide permettant d'incarner la valeur ajoutée.

Graphes et connaissance

- Graphe orienté ou non orienté : G = (V, E) avec V = nœuds (entités), E = arêtes (relations).
- Linked Property Graph (LPG) : chaque nœud/arête peut avoir des propriétés clé-valeur.
- Requête sur graphe : trouver des sous-graphes isomorphes, calcul de chemins, recherche de motifs.

Sémantique, ontologies

 Ontologie : formalise les concepts et relations d'un domaine (ex : OWL, RDF Schema); utile pour donner du sens et permettre des inférences au-delà du simple graphe.

Vectorisation et recherche sémantique

 Embeddings : vectorisation des nœuds/document associés pour calculer la similarité (cosinus, euclidienne) :

$$\cos(\theta) = \frac{\mathsf{v}_1 \cdot \mathsf{v}_2}{\|\mathsf{v}_1\| \|\mathsf{v}_2\|}$$

Techniques courantes: Word2Vec, GloVe, transformers (BERT/LLM).

IA et NLP

- Extraction d'entités : reconnaissance automatique des entités dans un texte.
- Similarité sémantique : utiliser des modèles de langage pour relier de nouveaux cas à l'historique.

Algorithmes fondamentaux

- Algorithme de parcours de graphe (DFS, BFS).
- Pagerank pour déterminer l'importance d'un nœud.
- Recherche de plus courts chemins (Dijkstra, A*).
- Recherche de sous-graphes similaires (isomorphisme de sous-graphe, graph embedding).

Exemple d'algorithme : BFS en C#

```
1 Queue < Node > queue = new Queue < Node > ();
2 HashSet < Node > visited = new HashSet < Node > ();
g queue. Enqueue (startNode);
 while (queue.Count > 0)
6 {
      Node current = queue.Dequeue();
7
      if (!visited.Contains(current))
          visited.Add(current):
LO
          foreach (Node neighbor in current. Neighbors)
12
               queue. Enqueue (neighbor);
13
```

Exemple de similarité cosinus entre deux embeddings

```
public double CosineSimilarity(double[] v1, double[]
    v2)
2 {
     double dot = 0.0, mag1 = 0.0, mag2 = 0.0;
     for (int i = 0; i < v1.Length; i++)</pre>
          dot += v1[i] * v2[i];
6
          mag1 += v1[i] * v1[i];
7
          mag2 += v2[i] * v2[i];
     return dot / (Math.Sqrt(mag1) * Math.Sqrt(mag2));
```

PageRank

Formule de base :

$$PR(u) = \frac{1-d}{N} + d\sum_{v \in B_u} \frac{PR(v)}{L(v)}$$

avec d = facteur d'amortissement (classiquement 0.85), N = nombre total de nœuds.

Définition d'un nœud et d'une relation en C#

```
1 public class Node
      public string Id { get; set; }
      public Dictionary < string , object > Properties { get
         ; set; }
5 }
7 public class Relationship
      public Node From { get; set; }
      public Node To { get; set; }
LO
      public string Type { get; set; }
11
      public Dictionary < string, object > Properties { get
12
         ; set; }
13 }
```

Recherche des voisins d'un nœud (extraction de sous-graphe)